

# 第八章 参数估计

参数是刻画总体某方面概率特性的数量指标。

实际问题中，往往是总体分布类型已知，但所含参数未知，从总体抽出一个样本，用某种方法对这个未知参数进行估计就是**参数估计**。

例如，总体  $X \sim N(\mu, \sigma^2)$ ,

若  $\mu, \sigma^2$  未知, 通过构造样本的函数, 给出它们的**估计值**或**取值范围**就是参数估计的内容.

点估计

区间估计

# 参数估计的类型

**点估计**——估计未知参数的值

**区间估计**——  
估计未知参数的取值范围，  
并使此范围包含未知参数  
真值的概率为给定的值。

## § 8.1 点估计

设 $X$  是总体，其分布函数为 $F(x, \theta)$ ， $\theta$ 是未知参数， $X_1, X_2, \dots, X_n$  是 $X$  的样本。现构造统计量  $\mathcal{S} = \mathcal{S}(X_1, X_2, \dots, X_n)$  来估计未知参数 $\theta$ 。将抽样后的样本值  $x_1, x_2, \dots, x_n$  代入上述统计量而得一具体数值  $\mathcal{S} = \mathcal{S}(x_1, x_2, \dots, x_n)$  这个数值就称为 $\theta$  的一个估计值，而  $\mathcal{S} = \mathcal{S}(X_1, X_2, \dots, X_n)$  称为  $\theta$  的一个估计量（一个随机变量）。这样的估计量以及估计值均称为  $\theta$  的一个点估计，相应的估计值（量）称为点估计值（点估计量），均简记  $\mathcal{S}$ 。

**从上述点估计的定义，似乎样本的任何一个统计量都可以作为未知参数 $\theta$ 的点估计量？实际上不行！统计量  $\mathcal{S} = \mathcal{S}(X_1, X_2, \dots, X_n)$  能作为 $\theta$ 的点估计量，必须要合理，需要满足一定的理论基础。下面，我们介绍两种常用的合理的点估计法：矩估计法和极大似然估计法。**

## 一、矩估计法（用样本矩作为总体矩的估计）

设总体 $X$  含有未知参数 $\theta$ ，则总体的分布函数可记为  $F(x, \theta)$ ，其中未知参数  $\theta = (\theta_1, \theta_2, \text{L}, \theta_k)$  是 $k$  维未知参数向量，即总体 $X$  含有 $k$  个未知参数。我们假设总体 $X$  的前 $k$  阶原点矩都存在。

(1) 建立总体原点矩与未知参数的关系：

$$m_r = E(X^r) = h_r(\theta_1, \theta_2, \text{L}, \theta_k), \quad r = 1, 2, \text{L}, k.$$

$$\text{即} \begin{cases} m_1 = h_1(\theta_1, \theta_2, \text{L}, \theta_k), \\ m_2 = h_2(\theta_1, \theta_2, \text{L}, \theta_k), \\ \text{L L L L L L L L} \\ m_k = h_k(\theta_1, \theta_2, \text{L}, \theta_k), \end{cases}$$

(2) 由上述方程组可以解出未知参数  $\theta_1, \theta_2, \dots, \theta_k$  即有

$$\begin{cases} \theta_1 = g_1(m_1, m_2, \dots, m_k), \\ \theta_2 = g_2(m_1, m_2, \dots, m_k), \\ \dots \\ \theta_k = g_k(m_1, m_2, \dots, m_k), \end{cases}$$

(3) 用样本原点矩替换相应的总体原点矩，从而得到点估计量

$$\begin{cases} \hat{\theta}_1 = g_1(A_1, A_2, \dots, A_k) = \hat{\theta}_1(X_1, X_2, \dots, X_n), \\ \hat{\theta}_2 = g_2(A_1, A_2, \dots, A_k) = \hat{\theta}_2(X_1, X_2, \dots, X_n), \\ \dots \\ \hat{\theta}_k = g_k(A_1, A_2, \dots, A_k) = \hat{\theta}_k(X_1, X_2, \dots, X_n), \end{cases}$$

则称  $\hat{\theta}_i$  为  $\theta_i$  的矩估计量，这种参数估计法就是矩估计法。

## 矩估计理论基础:

矩估计法是合理的, 是因为:

(1) 由大数定理知:

$$A_r = \frac{1}{n} \sum_{i=1}^n X_i^r \xrightarrow{P} m_r = E(A_r) (r = 1, 2, \dots, k).$$

(2) 更一般地, 样本矩的连续函数依概率收敛到**对应**的总体矩的连续函数。设g是连续函数, 则

$$g(A_1, A_2, \dots, A_r) \xrightarrow{P} g(m_1, m_2, \dots, m_r).$$

$$g(B_1, B_2, \dots, B_r) \xrightarrow{P} g(\mu_1, \mu_2, \dots, \mu_r).$$

**例、已知总体X 的密度函数为**

$$f(x) = \begin{cases} \theta c^\theta x^{-\theta-1}, & x > c, \\ 0, & x \leq c, \end{cases}$$

**其中  $c$  为已知正常数,  $\theta > 1$  是未知参数。设  $X_1, X_2, \dots, X_n$  总体X 的一个样本。**

**(1) 求 $\theta$ 的矩估计量**

**(2) 若有样本8.9, 9.2, 7.5, 8.0, 8.8, 7.9, 8.4, 8.6, 9.0, 8.7 且  $c = 3.5$ , 求 $\theta$  的矩估计值**



**解: (1)因总体仅含有一个未知参数, 故考虑用总体的1阶原点矩**

$$m_1 = E(X) = \int_{-\infty}^{+\infty} xf(x)dx = \int_c^{+\infty} x\theta c^\theta x^{-\theta-1}dx = \frac{c\theta}{\theta-1},$$

解出 $\theta$ 得到

$$\theta = \frac{m_1}{m_1 - c}$$

**用样本的1阶原点矩 $A_1$  替换总体的1阶原点矩  $m_1$ , 得到 $\theta$ 的矩估计量:**

$$\hat{\theta} = \frac{A_1}{A_1 - c} = \frac{\bar{X}}{\bar{X} - c}$$

**(2) 由样本观测值得样本均值为  $\bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i = 8.5$ ,**

**则 $\hat{\theta} = \frac{\bar{x}}{\bar{x} - c} = \frac{8.5}{8.5 - 3.5} = 1.7$ ,即  $\hat{\theta}$ 为 $\theta$ 的矩估计值**

**定理(例8.2)** 设 $X$  是任意总体，数学期望  $E(X) = u$ 和方差 $D(X) = \sigma^2$ 均存在，其中 $u, \sigma^2$ 为未知参数，则  $u, \sigma^2$  的矩估计量分别为  $\hat{u} = \bar{X}$ ,  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = B_2$ .

**证明：** 由于总体含有两个未知参数，故考虑总体的1, 2阶原点矩

$$m_1 = E(X) = u, \quad m_2 = E(X^2) = D(X) + (E(X))^2 = \sigma^2 + u^2,$$

解出未知参数  $\begin{cases} u = m_1 \\ \sigma^2 = m_2 - u^2 \end{cases}$       样本原点矩替换相应的总体矩得到矩估计量

$$\begin{cases} \hat{u} = \bar{X}, \\ \hat{\sigma}^2 = A_2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = B_2. \end{cases}$$

**例：**设总体  $X \sim \Gamma(\alpha, \beta)$ , 其中  $\alpha, \beta$  未知,  $X_1, X_2, \dots, X_n$  为  $X$  的样本, 求  $\alpha, \beta$  的矩估计量。

**解：**因  $m_1 = E(X) = \frac{\alpha}{\beta}, \mu_2 = D(X) = \frac{\alpha}{\beta^2}$ , 解得

$$\begin{cases} \alpha = \frac{[E(X)]^2}{D(X)} = \frac{m_1^2}{\mu_2} \\ \beta = \frac{E(X)}{D(X)} = \frac{m_1}{\mu_2} \end{cases} \quad \text{替换} \quad \begin{cases} \hat{\alpha} = \frac{\bar{X}^2}{B_2} \\ \hat{\beta} = \frac{\bar{X}}{B_2} \end{cases}$$

**结论：**若  $\hat{\theta}$  为  $\theta$  的矩估计量,  $g(x)$  为连续函数, 则  $g(\hat{\theta})$  为  $g(\theta)$  的矩估计。

**结论:** 若  $\mathcal{S}$  为  $\theta$  的矩估计量,  $g(x)$  为连续函数, 则  $g(\mathcal{S})$  为  $g(\theta)$  的矩估计。

**练习:** 设总体  $X \sim P(\lambda)$ ,  $\lambda$  未知, 用矩估计法估计  $h(\lambda) = 3\lambda^2 + 1$ 。

**解:**  $E(X) = \lambda$  由前面定理知,  $\mathcal{S} = \bar{X}$ , 而  $h(\lambda)$  是  $\lambda$  的连续函数, 则  $h(\lambda)$  的矩估计为  $\hat{h}(\lambda) = h(\mathcal{S}) = 3\mathcal{S}^2 + 1 = 3\bar{X}^2 + 1$ 。

此外,  $3B_2^2 + 1$  也是  $h(\lambda) = 3\lambda^2 + 1$  矩估计量。

这是因为  $D(X) = \lambda$ , 而  $B_2$  是方差的矩估计量, 从而

$3B_2^2 + 1$  也是  $h(\lambda) = 3\lambda^2 + 1$  矩估计量。

**说明:** (1) 矩估计法的基本原理: 用样本矩作为总体矩的估计; (2) 矩估计 (值或量) 不一定唯一。例如 Poisson 分布的参数  $\lambda$ , 既是总体均值, 又是总体方差。按照矩估计方法, 既可以用  $\bar{x}$  来估计, 也可以用  $b_2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$  来估计, 遇到这种情形, 总是选低阶矩的估计。

## 二、极大似然估计法

一个随机试验有多种可能结果，一次抽样中，结果A发生了，则我们认为A是全部可能结果中发生概率最大的那一个。

**引例：**一袋小球分为黑白两种，形状一样，现要估计白球所占的百分比 $p$ 。为此有放回的抽取10次，每次一个小球。引入随机变量  $X_i$ ,

$$X_i = \begin{cases} 1, & \text{第}i\text{次摸得白球,} \\ 0, & \text{第}i\text{次摸得黑球.} \end{cases} \quad \text{则 } X_i \sim B(1, p), i = 1, 2, \dots, 10.$$

试验的结果是(1, 0, 1, 0, 0, 0, 1, 0, 0, 0)

**这表明此次抽样中事件**

$$A = \left\{ \begin{array}{l} X_1 = 1, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 0, \\ X_6 = 0, X_7 = 1, X_8 = 0, X_9 = 0, X_{10} = 0 \end{array} \right\}$$

**发生了。考察A发生的概率**  $P(A) = p^3(1-p)^7$ .

**A事件发生的概率与p有关，可看作p的函数：**

$$L(p) = P(A) = p^3(1-p)^7.$$

**抽样的结果有很多种可能，为何在一次抽样中A就出现了呢？我们认为是试验的条件（对应于p的值）使得结果A出现的概率最大！利用微积分的知识，可解得当 $p=0.3$ 时， $P(A)$ 达到最大概率。从而可估计白球所占比例为30%。**

总结上面的想法就是： 一个随机事件有若干个可能的结果，若在一次抽样中某一结果出现了，我们自然地认为，该结果是若干个可能结果中发生概率最大的一个，因此参数的取值应使得已发生的事件概率最大。这种想法就是极大似然估计法的基本思想。

1、当总体 $X$ 离散且分布律为 $p(X=x) = p(x, \theta)$  时，其中 $\theta$ 是未知参数，且样本  $X_1, X_2, \dots, X_n$  的观察值为 $x_1, x_2, \dots, x_n$ 时，则事件 $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$ 发生的概率为

$$\begin{aligned} L(\theta) &= P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) \\ &= \prod_{i=1}^n P(X_i = x_i) = \prod_{i=1}^n p(x_i, \theta) \end{aligned}$$



由极大似然估计法的思想， $\theta$ 的极大似然估计值  $\hat{\theta}$  应使得  $L(\theta)$ （即已发生事件  $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$  发生的概率）达到最大，即 应是

$$L(\hat{\theta}) = \max_{\theta} L(\theta)$$

的解。  $L(\theta)$  称为似然函数。

2、当总体  $X$  为连续型且密度函数为  $f(x, \theta)$  时，其中  $\theta$  是未知参数，且样本  $X_1, X_2, \dots, X_n$  的观察值为  $x_1, x_2, \dots, x_n$  时，因  $X_i$  落在  $x_i$  的邻域（设其长度为  $\Delta x_i$ ）内的近似概率为  $f(x_i, \theta) \Delta x_i, i = 1, 2, \dots, n$ ，则每个  $X_i$  都落在  $x_i$  的邻域（设其长度为  $\Delta x_i$ ）内发生的概率近似为

$$\prod_{i=1}^n f(x_i, \theta) \Delta x_i,$$

按照极大似然估计法的思想,  $\theta$  的估计值  $\$$  应使得

$$\prod_{i=1}^n f(x_i, \dot{\theta}) \Delta x_i = \max_{\theta} \prod_{i=1}^n f(x_i, \theta) \Delta x_i \quad (**)$$

由于  $\Delta x_i$  与  $\theta$  无关, 故

$$\prod_{i=1}^n f(x_i, \dot{\theta}) \Delta x_i = \left( \prod_{i=1}^n f(x_i, \dot{\theta}) \right) \left( \prod_{i=1}^n \Delta x_i \right)$$

于是 **(\*\*)** 等价于  $\prod_{i=1}^n f(x_i, \$) = \max_{\theta} \prod_{i=1}^n f(x_i, \theta)$

让  $L(\theta) = \prod_{i=1}^n f(x_i, \theta)$

则  $\theta$  的估计值  $\$$  应满足  $L(\$) = \max_{\theta} L(\theta)$  我们称  $L(\theta)$  为似然函数。

综上所述，我们有

**定义：** 设 $X$  为总体， $\theta$ 为参数，且总体的分布律或密度已知， $x_1, x_2, \dots, x_n$ 为一组样本观测值。若存在  $\theta$  的一个值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 使得 $L(\hat{\theta}) = \max L(\theta)$ 时，则称 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为  $\theta$  的极大似然估计值， $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为  $\theta$  的极大似然估计量。

按定义，极大似然估计值可以由方程  $\frac{dL(\theta)}{d\theta} = 0$  解得  $\theta = \hat{\theta}$ ，由于  $\ln L(\theta)$  和  $L(\theta)$  在同一处取得极值点，故上式的求解可通过求解  $\frac{d \ln L(\theta)}{d\theta} = 0$ 。

综上所述，求 $\theta$  的极大似然估计值的**一般步骤**：

(1) 写出似然函数

$$L(\theta) = \prod_{i=1}^n p(x_i, \theta) \quad (or \quad \prod_{i=1}^n f(x_i, \theta))$$

(2) 求出  $\ln L(\theta)$

(3) 令  $\frac{d \ln L(\theta)}{d\theta} = 0$ , 求 $\theta$  。

**例8.6** 设总体  $X \sim B(m, p)$ ,  $x_1, x_2, \dots, x_n$  为样本观测值, 其中  $m$  已知而  $p$  未知。求  $p$  的极大似然估计值和极大似然估计量。

**解：** 总体  $X$  的分布律为

$$p(x, p) = C_m^x p^x (1-p)^{m-x}, \quad x = 0, 1, 2, \dots, m$$

从而, 似然函数为

$$\begin{aligned} L(p) &= \prod_{i=1}^n p(x_i, p) = \prod_{i=1}^n C_m^{x_i} p^{x_i} (1-p)^{m-x_i} \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{mn - \sum_{i=1}^n x_i} \prod_{i=1}^n C_m^{x_i} \end{aligned}$$

则  $\ln L(p) = \sum_{i=1}^n x_i \ln p + (mn - \sum_{i=1}^n x_i) \ln(1-p) + \ln(\prod_{i=1}^n C_m^{x_i})$

令  $\frac{d \ln L(p)}{dp} = \frac{1}{p} \sum_{i=1}^n x_i - \frac{1}{1-p} (mn - \sum_{i=1}^n x_i) = 0$ , 解得

$p$  的极大似然估计值为  $\hat{p} = \frac{\sum_{i=1}^n x_i}{mn} = \frac{\bar{x}}{m}$ , 相应的,  $p$  的极大似然估计量为  $\hat{p} = \frac{\bar{X}}{m}$ 。

**例题：** 设总体  $X \sim e(\theta)$ ,  $x_1, x_2, \dots, x_n$  为样本观测值  
求  $\theta$  的极大似然估计。

**解：** 总体X 密度函数为  $f(x, \theta) = \begin{cases} \theta e^{-\theta x}, & x > 0, \\ 0, & x \leq 0, \end{cases}$

似然函数为 
$$L(\theta) = \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n e^{-\theta \sum_{i=1}^n x_i}$$

于是,  $\ln L(\theta) = n \ln \theta - \theta \sum_{i=1}^n x_i$ , 令  $\frac{d \ln L(\theta)}{d \theta} = \frac{n}{\theta} - \sum_{i=1}^n x_i = 0$ ,

解得  $\theta$  的极大似然估计值为  $\hat{\theta} = \frac{n}{\sum_{i=1}^n x_i}$ , 相应的,  $\frac{1}{\theta}$  的极大

似然估计量为  $\hat{\theta} = \frac{1}{\bar{X}}$

**思考题：** 设总体  $X \sim e(\lambda)$ ,  $x_1, x_2, \dots, x_n$  为样本观测值, 求  $\lambda$  的矩估计。

**结论：**  $\eta = g(\theta)$  具有单值反函数,  $\hat{\theta}$  为  $\theta$  的极大似然估计, 则  $\hat{\eta} = g(\hat{\theta})$  为  $\eta = g(\theta)$  的极大似然估计。

如在上例中,  $\theta > 0$  因而  $\frac{1}{\theta}$  的极大似然估计量为  $\hat{\eta} = \frac{1}{\hat{\theta}} = \bar{X}$



在前面的讨论中，所涉及未知参数均只有一个，如果未知参数为多个，即  $\theta = (\theta_1, \theta_2, \dots, \theta_n)$  时，似然函数为  $L(\theta_1, \theta_2, \dots, \theta_n)$ ，则  $\theta = (\theta_1, \theta_2, \dots, \theta_n)$  的极大似然估计值  $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_n)$  应由如下方程组求得。

$$\left\{ \begin{array}{l} \frac{\partial \ln L(\theta_1, \theta_2, \dots, \theta_n)}{\partial \theta_1} = 0 \\ \frac{\partial \ln L(\theta_1, \theta_2, \dots, \theta_n)}{\partial \theta_2} = 0 \\ \quad \quad \quad \text{L L L L L L L} \\ \frac{\partial \ln L(\theta_1, \theta_2, \dots, \theta_n)}{\partial \theta_n} = 0 \end{array} \right.$$

**例8.7：** 设总体  $X \sim N(u, \sigma^2)$ , 其中  $u, \sigma^2$  未知,  $x_1, x_2, \dots, x_n$  为  $X$  的一组样本观测值, 求  $u, \sigma^2$  的极大似然估计量。

**解：** 似然函数为

$$\begin{aligned} L(u, \sigma^2) &= \prod_{i=1}^n f(x_i; u, \sigma^2) \\ &= \prod_{i=1}^n \frac{e^{-\frac{(x_i - u)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} = (\sqrt{2\pi}\sigma)^{-n} e^{-\frac{\sum_{i=1}^n (x_i - u)^2}{2\sigma^2}}, \end{aligned}$$

$$\text{从而, } \ln L(u, \sigma^2) = -\frac{n}{2} \ln(2\pi) - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - u)^2$$

解方程组  $\begin{cases} \frac{\partial \ln L(u, \sigma^2)}{\partial u} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - u) = 0 \\ \frac{\partial \ln L(u, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - u)^2 \end{cases}$  得  $u, \sigma$  的

极大似然估计值为

$$\hat{u} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2;$$

相应的,  $u, \sigma$  的极大似然估计量为

$$\hat{u} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = B_2.$$

由此可见，当总体  $X \sim N(\mu, \sigma^2)$  时，矩估计量和极大似然估计量是相同的，均为

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = B_2.$$

一般来说，未知参数的矩估计和极大似然估计可以不一样。

需要注意的是，当  $\frac{dL(\theta)}{d\theta}$  无解时，极大似然估计值应该怎样取呢？

**例8.8：** 设总体  $X \sim U(0, \theta)$ ，未知  $\theta$ ， $x_1, x_2, \dots, x_n$  为样本观测值，求  $\theta$  的极大似然估计。

**解：** 似然函数为 
$$L(\theta) = \prod_{i=1}^n f(x_i, \theta) = \begin{cases} \frac{1}{\theta^n}, & 0 < x_i < \theta, \\ 0, & \text{else.} \end{cases}$$

由于  $\frac{dL(\theta)}{d\theta} = -n\theta^{-(n+1)} = 0$  在  $\theta > 0$  时无解，所以无法由该方程解出  $\theta$  的极大似然估计值  $\hat{\theta}$ 。

但另一方面，当  $\theta > 0$  时

$$\frac{dL(\theta)}{d\theta} = -n\theta^{-(n-1)} < 0,$$

故在  $\theta > 0$  时  $L(\theta)$  单调递减；同时每个  $x_i$  应满足  $0 \leq x_i \leq \theta$ ,

故  $0 \leq \max_i x_i \leq \theta$ , 所以  $\theta \geq \max_i x_i$  时,

$$L(\theta) = \max_{\theta} L(\theta),$$

即  $\theta$  的极大似然估计值为

$$\hat{\theta} = \max_i x_i;$$

$\theta$  的极大似然估计量为

$$\hat{\theta} = \max_i X_i.$$

可以看到，和极大似然估计法相比，矩估计的好处在于：无需知道总体的分布，就可以求出估计：不论总体是什么，对  $k$  阶原点矩的估计量总是  $\frac{1}{n} \sum_{i=1}^n x_i^k$ ，总是用样本均值  $\bar{x}$  估计总体均值，用样本的二阶中心矩  $b_2$  估计总体方差。但这也是它的缺点，即当知道总体分布的类型时，矩估计法和极大似然估计法相比，矩估计法没能利用分布类型提供的信息，其估计方法可能会不如极大似然估计法好。